

bigTpuProfile

bigTpuProfile is a performance visualization tool for accelerator cards (currently supports BM1690 only).

Table of Contents

- [bigTpuProfile](#)
 - [Table of Contents](#)
 - [Quick Start](#)
 - [Profile Data Export](#)
 - [Operators](#)
 - [tpu-train/tgi](#)
 - [tpudnn](#)
 - [bmodel](#)
 - [Visualization](#)
 - [Data Analysis](#)
 - [Directory Structure](#)
 - [doc](#)
 - [web](#)
 - [License](#)

Quick Start

Using bigTpuProfile involves two main steps:

1. Profile data export
2. Visualization through tpu-mlir

Profile Data Export

Operators

1. bigTpuProfile offers three modes:
 - Mode 0 (PMU only): Focuses on temporal dimensions without operator command details (minimal performance impact)
 - Mode 1 (Condensed commands): Tracks command types within operators (moderate performance impact, ~4% overhead, DMA bandwidth statistics may be inaccurate)
 - Mode 2 (Detailed commands): Captures comprehensive command details, typically for debugging and DMA bandwidth analysis (7-10% overhead)
2. `max_record_num` specifies the maximum number of profile records. Ensure this value exceeds your expected record count.

3. Profile output file naming convention:

`cdm_profile_data_dev{DeviceID}-{CallNum}`

Profiles can run independently on multiple devices (marked by DeviceID) or be called multiple times on the same device (CallNum).

tpu-train/tgi

```
torch.ops.my_ops.enable_profile(max_record_num, mode) # Start recording (mode:
0 PMU only, 1 condensed commands, 2 detailed commands)
torch.ops.my_ops.disable_profile() # Stop recording
```

```
# tpu-train example
# part 0
torch.ops.my_ops.enable_profile(max_record_num, 0) # Enable profile without cmd
info
_ = a tpu * b tpu
torch.ops.my_ops.disable_profile() # Output: cdm_profile_data_dev0-0

# part 1
torch.ops.my_ops.enable_profile(max_record_num, 1) # Enable profile with
condensed cmd info
_ = a tpu + b tpu
torch.ops.my_ops.disable_profile() # Output: cdm_profile_data_dev0-1

# part 2
torch.ops.my_ops.enable_profile(max_record_num, 2) # Enable profile with
detailed cmd info
_ = a tpu + b tpu
torch.ops.my_ops.disable_profile() # Output: cdm_profile_data_dev0-2
```

```
# tgi (text-generation-inference) example
# test_whole_parallel.py

def test_whole_model(batches=1, model_id="llama", model_path="/data",
quantize=None, mode="chat"):
    .....
    for it in range(2):
        .....
        for i in range(DECODE_TOKEN_LEN):
            os.environ["TOKEN_IDX"] = str(i)
            generate_start = time.time_ns()
            generations, next_batch, (forward_ns, decode_ns) =
model.generate_token(
                next_batch
            )
            generate_end = time.time_ns()
            time_list.append(generate_end - generate_start)
            for generation in generations:
                if i == 0:
                    generated_text[generation.request_id] =
generation.tokens.texts[0]
                else:
                    generated_text[generation.request_id] +=
generation.tokens.texts[0]
                if decode_only and enable_profile and it > 0 and i == 0:
                    # condition
                    torch.ops.my_ops.enable_profile(max_record_num, book_keeping)
                    # enable profile
                    logger.info(f"Token {i} {[g.tokens.texts[0] for g in generations]}")
                    if next_batch is None:
                        break
```

```

        if enable_profile and it > 0:
            # condition
            torch_tpu.tpu.optimizer_utils.OpTimer_dump()
            torch.ops.my_ops.disable_profile()
            # disable profile
        .....

```

tpudnn

```

// Assuming handle type: tpudnnHandle_t
auto pimpl = static_cast<TPUDNNImpl *>(handle);

pimpl->enableProfile(max_record_num, mode); // Start recording
pimpl->disableProfile(); // Stop recording

```

```

// tpudnn example
const int group_num = 1;
const int group_size = pimpl->getCoreNum();

pimpl->enableProfile(); // Enable profile
status = pimpl->launchKernel("gelu_forward_multi_core", &api, sizeof(api),
group_num, group_size);
pimpl->disableProfile(); // Disable profile

pimpl->enableProfile(80); // Enable profile with record limit
status = pimpl->launchKernel("gelu_forward_multi_core", &api, sizeof(api),
group_num, group_size);
pimpl->disableProfile(); // Disable profile

```

bmodel

For bmodel, control is through environment variables (no mode setting required):

- `ENABLE_ALL_PROFILE=1`: Enable profiling
- `TPUKERNEL_FIRMWARE_PATH=/path/to/libfirmware_core.so`: Specify firmware (required for older bmodel versions)
- `PROFILE_MODE`: (optional, values: 1 or 2) Enable extra profiling detail (e.g. input/output data transfers).
- `PROFILE_RECORD_SIZE`: Set the maximum number of PMU records.

```

# With default firmware and record limits
ENABLE_ALL_PROFILE=1 tpu-model-rt --bmodel ./xxx.bmodel

# With custom firmware, record limits and inputs outputs data transfers info
TPUKERNEL_FIRMWARE_PATH=/home/xxx/libfirmware_core.so ENABLE_ALL_PROFILE=1
PROFILE_MODE=2 PROFILE_RECORD_SIZE=40960 tpu-model-rt --bmodel ./xxx.bmodel

```

Visualization

Parse and visualize `cdm_profile_data_devx-x` using bigTpuProfile:

```
# bigTpuProfile -h for more details
bigTpuProfile cdm_profile_data_devX-X/ result_out --arch BM1690 # The
visualization results are stored in result_out
```

Data Analysis

Directory Structure

```
/result_out/
├─ tiuRegInfo_x
├─ tdmaRegInfo_x
├─ cdmaRegInfo_x
├─ PerfDoc      # Document visualization
├─ PerfWeb      # Web visualization
```

doc


PerfAI_output.xlsx contains overviews and detailed engine data (TIU, GDMA, SDMA, CDMA) per core.

Naming convention: engineType_coreId

5																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																																					</
---	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	--	----

web


result.html provides overviews, core-specific visualizations, and cross-core comparisons.



Features:

- Zoom with mouse wheel or slider


- Hover over commands to view details (match via global_idx in document)



Additional analysis options (TIU uArch Rate not yet supported):

category: -- func_type: --

☐ Show data ☐ Show localmem ☐ TIU uArch Rate



License

bigTpuProfile is licensed under the 2-Clause BSD License, excluding third-party components.